

Apprentissage en grande dimension

January 25, 2017

$$\min_{\beta \in \mathbb{R}} f(\beta) \quad (1)$$

Conditions: f convexe:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \quad (2)$$

Definition 1:

$$\forall \theta \in [0, 1] \quad (3)$$

Def 3 M

Def 4 Lipschitzienne

$$\forall x, y \|f(x) - f(y)\|_2 \leq L \|x - y\|_2 \quad (4)$$

Def 5 contractant

$$L \text{ Lipschitz avec } 0 \leq L < 1 \quad (5)$$

Thm 1 Thm point fixe: f est α -contractant,

$$\exists x^* \text{ tel que } f^* = f(x^*) \quad (6)$$

La suite définie par $x_{n+1} = f(x_n)$ converge vers x^* et vérifie

$$\|x_n - x^*\|_2 \leq \frac{\alpha^n}{1 - \alpha} \|x_0 - x_1\|_2 \quad (7)$$

Gradient Algo

Prop 5 Gradient monotone f diff est convexe, si et seulement si

$$\begin{aligned} (\nabla f(x) - \nabla f(y))^T (x - y) &\geq 0 \\ &= \nabla f(x)^T x - \nabla f(y)^T y \end{aligned} \quad (8)$$

PREUVE 1. \Rightarrow :

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \quad (9)$$

$$f(x) \geq f(y) + \nabla f(y)^T (x - y) \quad (10)$$

$$-f(x) - f(y) < -f(x) - f(y) + \nabla f(x)^T (x - y) - \nabla f(y)^T (x - y) \quad (11)$$

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq 0 \quad (12)$$

2. \Leftarrow : On introduit une fonction Φ :

$$\Phi(t) = f(x + t(y - x)) \quad (13)$$

$$\Phi'(t) = \nabla f(x + t(y - x))^T (y - x) \quad (14)$$

Comme ∇f est monotone

$$\Phi'(t) \geq \Phi'(0), t \geq 0 \quad (15)$$

$$f(y) - \Phi(1) = \Phi(0) + \int_0^1 \Phi'(t)dt \quad (16)$$

$$f(y) \geq \Phi(0) + \Phi'(0) = f(x) + \nabla f(x)^T(y - x) \quad (17)$$

Theorème Boîte quadratique supérieure

$$f \sim L^1, \nabla f \text{ est } L\text{-lipschitz} \quad (18)$$

Alors

$$g(x) = \frac{L}{2}x^Tx - f(x) \text{ est convexe} \quad (19)$$

$$f(y) \leq \nabla f(x)^T(y - x) + \frac{L}{2}\|x - y\|_2^2 \quad (20)$$

1. ∇f Lipschitz

$$\|\nabla f(y) - \nabla f(x)\|_2 \leq L\|y - x\|_2 \quad (21)$$

2.

$$\begin{aligned} (\nabla f(y) - \nabla f(x))^T(y - x) &\leq \|\nabla f(y) - \nabla f(x)\|_2 \|y - x\|_2 \\ &\leq L\|y - x\|_2^2 \end{aligned} \quad (22)$$

$$\nabla g(x) = Lx - \nabla f \quad (23)$$

$$\begin{aligned} &(\nabla g(x) - \nabla g(y))^T(x - y) \\ &= (Lx - \nabla f(x) - Ly + \nabla f(y))^T(x - y) \\ &= -(\nabla f(y) - \nabla f(x))^T(y - x) + L\|x - y\|_2^2 \\ &\geq 0 \end{aligned} \quad (24)$$

$$y = x - t\nabla f(x) \quad (25)$$

$$f(x - t\nabla f(x)) \leq f(x) + t(1 - \frac{Lt}{2})\|\nabla f(x)\|_2^2 \quad (26)$$

choix de t tel que $0 \leq t < \frac{1}{2}$

$$x^+ = x - t\nabla f(x) \quad (27)$$

$$\begin{aligned} f(x^+) &\leq f(x) + t(1 - \frac{Lt}{2})\|\nabla f(x)\|_2^2 \\ &\leq f(x) - \frac{t}{2}\|\nabla f(x)\|_2^2 \\ &\leq f^* + \nabla f(x)^T(x - x^*) - \frac{t}{2}\|\nabla f(x)\|^2 \\ &= f^* + \frac{1}{2t}(\|x - x^*\|_2^2 - \|x - x^* - t\nabla f(x)\|_2^2) \\ &= f^* + \frac{1}{2t}(\|x - x^*\|_2^2 - \|x^+ - x^*\|_2^2) \end{aligned} \quad (28)$$

$$\begin{aligned}
\sum_{k=1}^N (f(x_k) - k^*) &\leq \frac{1}{2t} \sum_{k=1}^N (\|x_{k-1} - x^*\|_2^2 - \|x_k - x^*\|_2^2) \\
&= \frac{1}{2t} (\|x_0 - x^*\|_2^2 - \|x_N - x^*\|_2^2) \\
&\leq \frac{1}{2t} \|x_0 - x^*\|_2^2
\end{aligned} \tag{29}$$

Prop: Quand f est différentiable

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \tag{30}$$

Definition: sous gradient g est un sous gradient de f en x , ssi

$$\forall y, f(y) \geq f(x) + g^T (y - x) \tag{31}$$

Definition: sous différentielle f convexe, on définit la sous différentielle de f en x comme

$$\partial f(x) = \{g | \forall y, f(y) \geq f(x) + g^T (y - x)\} \tag{32}$$

Theoreme 3:

$$x^* = \operatorname{argmin} f \Leftrightarrow 0 \in \partial f(x^*) \tag{33}$$

Si $0 \in \partial f(x^*)$, alors

$$\forall y, f(y) \geq f(x^*) + 0^T (y - x^*) \Leftrightarrow x^* = \operatorname{argmin} f \tag{34}$$

Prop 7: linéarité non négative f_1 et f_2 convexes, $\alpha_1, \alpha_2 \geq 0$

$$f \geq \partial(\alpha_1 f_1 + \alpha_2 f_2)(x) = \alpha_1 \partial f_1(x) + \alpha_2 \partial f_2(x) \tag{35}$$

+ addition d'ensemble

$$E + F = \{e + f | e \in E, f \in F\} \tag{36}$$

Prop 8: combinaison affine: Si $h(x) = f(Ax + b)$, alors

$$\partial h(x) = A^T \partial f(Ax + b) \tag{37}$$

f est une fonction G -Lipschitzienne

ALGO: Méthode du "sous-gradient"

$$x_k \leftarrow x_{k-1} - t_k g_{k-1} \tag{38}$$

ou

$$g_{k-1} \in \partial f(x_{k-1}) \tag{39}$$

Trois possibilités pour t_k

1. $t_k = t$

2. "Longueur constante" $t_k \|g_{k-1}\|_2$ est constante

3.

$$t_k \rightarrow_{k \rightarrow +\infty} 0 \quad (40)$$

$$\sum_{k=1}^{+\infty} = +\infty \quad (41)$$

$$\sum_{k=1}^{+\infty} t_k^2 = \text{limite finie} \quad (42)$$

Theoreme: f convexe et non differentielle f est G -Lipschitzienne $\Leftrightarrow \|g\|_2 \leq G, \forall g \in \partial f(x)$

Preuve: \Leftarrow

On suppose $\forall x, \forall g \in \partial f(x)$

$$\|g\|_2 \leq G \quad (43)$$

Soit $x(g_x)$ et $y(g_y)$

$$g_x^T(x - y) \geq f(x) - f(y) \geq g_y^T(x - y) \quad (44)$$

$$G\|x - y\|_2 \geq f(x) - f(y) \geq -G\|x - y\|_2 \quad (45)$$

$$\forall x, y, \|f(x) - f(y)\| \leq G\|x - y\|_2 \quad (46)$$

$\Rightarrow \exists g$ tel que $\|g\|_2 > G$

$$y = x + \frac{g}{\|g\|_2} \quad (47)$$

$$f(y) \geq f(x) + g^T(y - x) = f(x) + \|g\|_2 > f(x) + G \quad (48)$$

Pas possible car f est G -Lipschitzienne

Attention: La méthode du sous-gradient n'est pas une méthode de descente.

$$x^+ = tg \quad (49)$$

g sous-gradient de f en x .

$$\begin{aligned} \|x^+ - x^*\|_2^2 &= \|x - tg - x^*\|_2^2 \\ &= \|x - x^*\|_2^2 + t^2\|g\|_2^2 - 2tg^T(x - x^*) \\ &\leq \|x - x^*\|_2^2 + t^2\|g\|_2^2 - 2t(f(x) - f^*) \end{aligned} \quad (50)$$

Pour une iteration k :

$$2t_k(f(x_{k-1}) - f^*) < \|x_{k-1} - x^*\|_2^2 - \|x_k - x^*\|_2^2 + t_k^2\|g_{k-1}\|_2^2 \quad (51)$$

en sommant les inégalités

$$\begin{aligned}
2\left(\sum_{k=1}^N t_k\right)(f_{best}^{(N)} - f^*) &\leq \|x_0 - x^*\|_2^2 - \|x_N - x^*\|_2^2 + \sum_{k=1}^N t_k^2 \|g_{k-1}\|_2^2 \\
&\leq \|x_0 - x^*\|_2^2 + \sum_{k=1}^N t_k^2 \|g_{k-1}\|_2^2
\end{aligned} \tag{52}$$

1. $t_k = t$

$$f_{best}^{(N)} - f^* \leq \frac{\|x_0 - x^*\|_2^2}{2Nt} + \frac{G^2 t}{2} \tag{53}$$

2. $t_k \|g_{k-1}\|_2 = s$

$$f_{best}^{(N)} - f^* \leq \frac{G\|x_0 - x^*\|_2^2}{2Ns} + \frac{Gs}{2} \tag{54}$$

3. $t_k \rightarrow 0, \sum t_k \rightarrow +\infty, \sum t_k^2$ converge

$$f_{best}^{(N)} - f^* \leq \frac{\|x_0 - x^*\|_2^2 + \sigma^2 \sum t_k^2}{2 \sum t_k} \tag{55}$$

Conclusion: La méthode du sous gradient n'est pas facile à paramétrer pour obtenir sa convergence.

Exercise:

$$f(\beta) = \|X\beta - y\|_2^2 + \lambda \|\beta\|_1 \tag{56}$$

$$\partial f(\beta) = X^T(X\beta - y) + \lambda \partial_{\|\cdot\|_1}(\beta) \tag{57}$$

$$[\partial_{\|\cdot\|_1}(\beta)] = \begin{cases} \text{sign}(\beta_i) & \text{si } \beta_i \neq 0 \\ [-1, 1] & \text{si } \beta_i = 0 \end{cases} \tag{58}$$

Definition Operateur proximal

$$\text{prox}_f(x) = \underset{u}{\operatorname{argmin}} \{f(u) + \frac{1}{2}\|u - x\|_2^2\} \tag{59}$$

f convexe "semi-continue inférieurement" (sci). alors, $\text{prox}_f(x)$ existe et est unique.

Theoreme Caractérisation par le sous-gradient

$$u = \text{prox}_f(x) \Leftrightarrow x - u \in \partial f(u) \tag{60}$$

Preuve:

$$\begin{aligned}
u = \text{prox}_f(x) &\Leftrightarrow u = \underset{u}{\operatorname{argmin}} \{f(u) + \frac{1}{2}\|u - x\|_2^2\} \\
&\Leftrightarrow 0 \in \partial g(u) \\
&\Leftrightarrow 0 \in \partial g_1(u) + \partial g_2(u) \\
&\Leftrightarrow 0 \in \partial f(u) + (u - x) \Leftrightarrow x - u \in \partial f(u)
\end{aligned} \tag{61}$$

$$g(y) = g_1(y) + g_2(y) = f(y) + \frac{1}{2} \|y - x\|_2^2 \quad (62)$$

Algorithme du gradient proximal

$$0 \in \partial f(x^*) \Leftrightarrow x^* = \operatorname{argmin}_x f(x) \quad (63)$$

$$\partial(f_1 + f_2) = \partial f_1 + \partial f_2 \quad (64)$$

Si f est différentiable en x , alors

$$\partial f(x) = \nabla f(x) \quad (65)$$

Norme euclidienne

$$f(x) = \|x\|_2 \quad (66)$$

$$\operatorname{prox}_{tf}(x) = \begin{cases} (1 - \frac{t}{\|x\|_2})x & , \|x\|_2 \geq t \\ 0 & , \text{sinon} \end{cases} \quad (67)$$

Multiplication par un scalaire $\lambda > 0$

$$f(x) = \lambda g(x/\lambda) \quad (68)$$

$$\operatorname{prox}_f(x) = \lambda \operatorname{prox}_{\frac{1}{\lambda}g}(\frac{x}{\lambda}) \quad (69)$$

Somme séparable (Group LASSO)

$$f([x, y]) = g(x) + h(y) \quad (70)$$

$$\operatorname{prox}_f([x, y]) = [\operatorname{prox}_g(x), \operatorname{prox}_h(y)] \quad (71)$$

Norme l_1

$$f(x) = \|x\|_1 \quad (72)$$

$$[\operatorname{prox}_f(x)]_i = \begin{cases} x_i - 1 & \text{si } x_i \geq 1 \\ 0 & \text{si } |x_i| < 1 \\ x_i + 1 & \text{si } x_i \leq -1 \end{cases} \quad (73)$$

Numériquement

$$\operatorname{prox}_{l_1}(x) = \operatorname{sign}(x) \times \max(\operatorname{abs}(x) - 1, 0) \quad (74)$$

$$\min_{\beta} f(\beta) = \min_{\beta} \{g(\beta) + h(\beta)\} \quad (75)$$

Algorithme du gradient proximal g convexe et différentiable, ∇g est L -Lipschitzienne

h convexe et non-différentiable (sci pour avoir $\operatorname{prox}_{l_2}(x)$)

Exercice

$$f(\beta) = \|X\beta - y\|_2^2 + \lambda \|\beta\|_1 \quad (76)$$

Algorithme:

$$x_k \leftarrow \operatorname{prox}_{t_k h}(x_{k-1} - t_k \nabla g(x_{k-1})) \quad (77)$$

$$f^* = f(x^*) \text{ fini} \quad (78)$$

$$t_k = \frac{1}{L}, (0 \leq t_k < \frac{1}{L}) \quad (79)$$

Gradient Map

$$G_t(x) = \frac{1}{t}(x - \text{prox}_{tL_2}(x - t\nabla g(x))) \quad (80)$$

Pourquoi?

$$x^+ = x - tG_t(x) \quad (81)$$

Attention:

- $G_t(x)$ n'est pas un gradient pour g , n'est pas un sous-gradient pour h ou pour f
- $G_t(x^*) = 0$ ssi $x^* = \text{argmin} f$

Borne Quadratique Supérieure (BQS)

$$g(y) \leq g(x) + \nabla g(x)^T(y - x) + \frac{L}{2}\|y - x\|_2^2 \quad (82)$$

Pour

$$y(= x^+) = x - tG_t(x) \quad (83)$$

$$\begin{aligned} g(x - tG_t(x)) &\leq g(x) - t\nabla g(x)^T G_t(x) + \frac{L}{2}t^2\|G_t(x)\|_2^2 \\ &\leq g(x) - t\nabla g(x)^T G_t(x) + \frac{t}{2}\|G_t(x)\|_2^2 \end{aligned} \quad (84)$$

Théorème: L'inégalité précédente nous permet de montrer

$$f(x - tG_t(x)) \leq f(z) + G_t(x)^T(x - z) - \frac{t}{2}\|G_t(x)\|_2^2 \quad (85)$$

$$\begin{aligned} f(x - tG_t(x)) &\leq g(x) - t\nabla g(x)^T G_t(x) + \frac{t}{2}\|G_t(x)\|_2^2 + h(x - tG_t(x)) \\ &\leq g(z) + \nabla g(z)^T(x - z) - t\nabla g(x)^T G_t(x) + \frac{t}{2}\|G_t(x)\|_2^2 + h(z) + v^T(x - z - tG_t(x)) \\ &= f(z) + G_t(x)^T(x - z) - \frac{t}{2}\|G_t(x)\|_2^2 \end{aligned} \quad (86)$$

Pour

$$z = x \quad (87)$$

on a

$$f(x^+) \leq f(x) - \frac{t}{2}\|G_t(x)\|_2^2 \quad (88)$$

$$f(x^+) \rightarrow f(x_k) \quad (89)$$

Donc, on a une méthode de descente !

Pour $z = x^*$

$$\begin{aligned} f(x^*) - f^* &\leq G_t(x)^T(x - x^*) - \frac{t}{2} \|G_t(x)\|_2^2 \\ &= \frac{1}{2t} (\|x - x^*\|_2^2 - \|x - x^* - tG_t(x)\|_2^2) \\ &= \frac{1}{2t} (\|x - x^*\|_2^2 - \|x^+ - x^*\|_2^2) \end{aligned} \quad (90)$$

$$f(x_N) - f^* \leq \frac{1}{2Nt} \|x_0 - x^*\|_2^2 \quad (91)$$

$$[prox_{t\|\cdot\|_1}](x) = \begin{cases} x_i - t & \text{si } x_i \geq t \\ 0 & \text{si } |x_i| < t \\ x_i + t & \text{si } x_i \leq -t \end{cases} \quad (92)$$

Fast Proximal gradient algorithm

Convexe & différentielle

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) \quad (93)$$

Sous-gradient — sous différentielle

$$\partial f(x) = \{g|g^T(x - y) \leq f(y) - f(x)\} \quad (94)$$

Prox.

$$prox_f(x) = \operatorname{argmin}_\mu \{f(\mu) + \frac{1}{2}\|x - \mu\|_2^2\} \quad (95)$$

$$x - u \in \partial f(u) \Leftrightarrow u = prox_f(x) \quad (96)$$

$$\min f(\beta) = g(\beta) + h(\beta) \quad (97)$$

∇g L-Lipschitzienne $prox_{th}$ convexe

FISTA: (n'est pas une méthode de descente)

$$y = x_{k-1} + \frac{k-2}{k+1}(x_{k-1} - x_{k-2}) \quad (98)$$

$$x_k = prox_{t_k h}(y - t_k \nabla g(y)) \quad (99)$$

$$t_k = \frac{1}{L} \text{constant} \quad (100)$$

Reformulation

$$\theta_k = \frac{2}{k+1} \quad (101)$$

v_k tel que $v_0 = x_0$ et $\forall k \geq 1$

$$\begin{cases} y = (1 - \theta_k)x_{k-1} + \theta_k v_{k-1} \\ x_k = \text{prox}_{th}(y - t_k \nabla g(y)) \\ v_k = x_{k-1} + \frac{1}{\theta_k}(x_k - x_{k-1}) \end{cases} \quad (102)$$

Inégalité

$$\forall k \geq 2, \frac{1 - \theta_k}{\theta_k} \leq \frac{1}{\theta_{k-1}^2} \quad (103)$$

BQS(g)

$$g(u) \leq g(z) + \nabla g^T(z)(u - z) + \frac{L}{2} \|u - z\|_2^2 \quad (104)$$

BQS(h)

$$u = \text{prox}_{th}(w) \quad (105)$$

alors

$$\forall z, h(u) \leq h(z) + \frac{1}{t}(v - u)^T(u - z) \quad (106)$$

1.

$$g(x^+) \leq g(y) + \nabla g^T(y)(x^+ - y) + \frac{1}{2t} \|x^+ - y\|_2^2 \quad (107)$$

2.

$$\begin{aligned} h(x^+) &\leq h(z) + \frac{1}{t}(y - t \nabla g(y)x^+)^T(x^+ - z) \\ &= h(z) + \nabla g(y)^T(z - x^+) + \frac{1}{t}(x^+ - y)^T(z - x^+) \end{aligned} \quad (108)$$

1+2:

$$\begin{aligned} f(x^+) &= g(x^+) + h(x^+) \\ &\leq g(y) + h(z) + \nabla g(y)^T(x^+ - y + z - x^+) + \frac{1}{2t} \|x^+ - y\|_2^2 + \frac{1}{t}(x^+ - y)^T(z - x^+) \\ &\leq f(z) + \frac{1}{2t} \|x^+ - y\|_2^2 + \frac{1}{t}(x^+ - y)^T(z - x^+) \end{aligned} \quad (109)$$

$$\begin{aligned} &f(x^+) - f^* - (1 - \theta)(f(x) - f^*) \\ &\leq \frac{\theta^2}{2t} (\|v - x^*\|_2^2 - \|v^+ - x^*\|_2^2) \\ &\Leftrightarrow \frac{t}{\theta^2} (f(x) - f^* + \frac{1}{2} \|v_1 - x^*\|_2^2) \leq \frac{1 - \theta_1^2}{\theta_1^2} (f(z) - f^*) + \frac{1}{2} \|v - x^*\|_2^2 \end{aligned} \quad (110)$$

Comme

$$\frac{1 - \theta_1}{\theta_1^2} \leq \frac{1}{\theta_{i-1}^2} \quad (111)$$

Conclusion

$$\frac{t}{\theta_k^2}(f(x_k) - f^*) - \frac{1}{2}\|v_1 - x^*\|_2^2 \leq \frac{(1 - \theta_1)^t}{\theta_1^2}(f(x_0) - f^*) + \frac{1}{2}\|v_0 - x^*\|_2^2 \quad (112)$$

Ainsi

$$\frac{t}{\theta_k^2}f(x_k) - f^* \leq \frac{(1 - \theta_1)^t}{\theta_1^2}(f(x_0) - f^*) + \frac{1}{2}\|v_k - x^*\|_2^2 - \frac{1}{2}\|v_0 - x^*\|_2^2 \quad (113)$$

$$f(x_k) - f^* \leq \frac{2L}{(k + 1)^2}\|x_0 - x^*\|_2^2 \quad (114)$$